

On the Properties of Neural Machine Translation: Encoder–Decoder Approaches

Kyunghyun Cho Bart van Merriënboer Dzmitry Bahdanau*
Université de Montréal Jacobs University, Germany

Yoshua Bengio
Université de Montréal, CIFAR Senior Fellow

Abstract

Neural machine translation is a relatively new approach to statistical machine translation based purely on neural networks. The neural machine translation models often consist of an encoder and a decoder. The encoder extracts a fixed-length representation from a variable-length input sentence, and the decoder generates a correct translation from this representation. In this paper, we focus on analyzing the properties of the neural machine translation using two models; RNN Encoder–Decoder and a newly proposed gated recursive convolutional neural network. We show that the neural machine translation performs relatively well on short sentences without unknown words, but its performance degrades rapidly as the length of the sentence and the number of unknown words increase. Furthermore, we find that the proposed gated recursive convolutional network learns a grammatical structure of a sentence automatically.

1 Introduction

A new approach for statistical machine translation based purely on neural networks has recently been proposed (Kalchbrenner and Blunsom, 2013; Sutskever et al., 2014). This new approach, which we refer to as *neural machine translation*, is inspired by the recent trend of deep representational learning. All the neural network models used in (Kalchbrenner and Blunsom, 2013; Sutskever et al., 2014; Cho et al., 2014) consist of an encoder and a decoder. The encoder extracts a fixed-length vector representation from a variable-length input sentence, and from this representation the decoder

generates a correct, variable-length target translation.

The emergence of the neural machine translation is highly significant, both practically and theoretically. Neural machine translation models require only a fraction of the memory needed by traditional statistical machine translation (SMT) models. The models we trained for this paper require only 500MB of memory in total. This stands in stark contrast with existing SMT systems, which often require tens of gigabytes of memory. This makes the neural machine translation appealing in practice. Furthermore, unlike conventional translation systems, each and every component of the neural translation model is trained jointly to maximize the translation performance.

As this approach is relatively new, there has not been much work on analyzing the properties and behavior of these models. For instance: What are the properties of sentences on which this approach performs better? How does the choice of source/target vocabulary affect the performance? In which cases does the neural machine translation fail?

It is crucial to understand the properties and behavior of this new neural machine translation approach in order to determine future research directions. Also, understanding the weaknesses and strengths of neural machine translation might lead to better ways of integrating SMT and neural machine translation systems.

In this paper, we analyze two neural machine translation models. One of them is the RNN Encoder–Decoder that was proposed recently in (Cho et al., 2014). The other model replaces the encoder in the RNN Encoder–Decoder model with a novel neural network, which we call a *gated recursive convolutional neural network* (grConv). We evaluate these two models on the task of translation from French to English.

* Research done while visiting Université de Montréal

神经机器翻译的属性研究：编码器-解码器架构

蒙特利尔大学‘雅各布斯大学’，德国，Kyunghyun Cho、Bart van Merriënboer、Dzmitry Bahdanau*

约书亚·本吉奥，CIFAR高级研究员，蒙特利尔大学

摘要

神经机器翻译是一种完全基于神经网络的统计机器翻译新方法。这类神经机器翻译模型通常由编码器和解码器组成：编码器负责从变长输入句子中提取固定长度的表征，解码器则依据该表征生成正确的译文。在本文中，我们通过两种模型——RNN编码器-解码器模型以及一种新提出的带门控的递归卷积神经网络——来分析神经机器翻译的各类属性。研究结果表明，对于不含未知词的短句，该技术能表现出较好的性能；但随着句子长度的增加以及未知词数量的增多，其性能会迅速下降。此外，我们还发现这种带门控的递归卷积神经网络能够自动学习句子的语法结构。

1 引言

最近有一种完全基于神经网络、用于统计机器翻译的新方法被提出（Kalchbrenner和Blunsom，2013年；Sutskever等人2014年的研究）。我们将这种新方法称为神经机器翻译，它的灵感源自近期兴起的深度表征学习趋势。在（Kalchbrenner和Blunsom，2013年；Sutskever等人2014年的研究；Cho等人2014年的研究）中使用的所有神经网络模型都由编码器和解码器组成：编码器会从变长输入的句子中提取出固定长度向量表示，而解码器则基于这一表示

*在访问蒙特利尔大学期间开展的研究

生成正确的、变长的目标译文。

神经机器翻译的出现无论从实际应用还是理论层面都具有极其重要的意义。神经机器翻译模型所需的内存仅是传统统计机器翻译（SMT）模型所需内存的一小部分。本文所训练的模型总共仅需500MB的内存，这与那些通常需要数十GB内存的现有SMT系统形成了鲜明对比，也正是这一优势使得神经机器翻译在实践中极具吸引力。此外，与传统翻译系统不同，神经机器翻译模型的每一个组件都是通过联合训练来提升翻译性能的。

由于这种方法相对较新，目前针对这些模型的特性与行为进行分析的研究还不多。例如：哪些类型的句子能让这种方法的翻译效果更佳？源语言/目标语言词汇的选择如何影响翻译性能？在何种情况下神经机器翻译会失效？

要明确未来研究的方向，首先必须深入了解这种新型神经机器翻译方法的特性与运行机制。同时，掌握神经机器翻译的优缺点，也有助于找到更有效的途径，将传统统计机器翻译模型与神经机器翻译系统相结合。

在本文中，我们分析了两种神经机器翻译模型。其中一种为近期在(Cho等人2014年的研究)中提出的RNN编码器-解码器架构；另一种模型则用一种全新的神经网络替换了该架构中的编码器，我们将这种网络称为带门控的递归卷积神经网络（即grConv模型）。我们在法语到英语的机器翻译任务上对这两种模型进行了评估。

Our analysis shows that the performance of the neural machine translation model degrades quickly as the length of a source sentence increases. Furthermore, we find that the vocabulary size has a high impact on the translation performance. Nonetheless, qualitatively we find that the both models are able to generate correct translations most of the time. Furthermore, the newly proposed grConv model is able to learn, without supervision, a kind of syntactic structure over the source language.

2 Neural Networks for Variable-Length Sequences

In this section, we describe two types of neural networks that are able to process variable-length sequences. These are the recurrent neural network and the proposed gated recursive convolutional neural network.

2.1 Recurrent Neural Network with Gated Hidden Neurons




Figure 1: The graphical illustration of (a) the recurrent neural network and (b) the hidden unit that adaptively forgets and remembers.

A recurrent neural network (RNN, Fig. 1 (a)) works on a variable-length sequence $x = (\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_T)$ by maintaining a hidden state $\mathbf{h}$ over time. At each timestep t , the hidden state $\mathbf{h}^{(t)}$ is updated by

$$\mathbf{h}^{(t)} = f(\mathbf{h}^{(t-1)}, \mathbf{x}_t),$$

where f is an activation function. Often f is as simple as performing a linear transformation on the input vectors, summing them, and applying an element-wise logistic sigmoid function.

An RNN can be used effectively to learn a distribution over a variable-length sequence by learning the distribution over the next input $p(\mathbf{x}_{t+1} | \mathbf{x}_t, \dots, \mathbf{x}_1)$. For instance, in the case of a sequence of 1-of- K vectors, the distribution can be learned by an RNN which has as an output

$$p(x_{t,j} = 1 | \mathbf{x}_{t-1}, \dots, \mathbf{x}_1) = \frac{\exp(\mathbf{w}_j \mathbf{h}_{(t)})}{\sum_{j'=1}^K \exp(\mathbf{w}_{j'} \mathbf{h}_{(t)})},$$

for all possible symbols $j = 1, \dots, K$, where $\mathbf{w}_j$ are the rows of a weight matrix $\mathbf{W}$. This results in the joint distribution

$$p(x) = \prod_{t=1}^T p(x_t | x_{t-1}, \dots, x_1).$$

Recently, in (Cho et al., 2014) a new activation function for RNNs was proposed. The new activation function augments the usual logistic sigmoid activation function with two gating units called reset, $\mathbf{r}$, and update, $\mathbf{z}$, gates. Each gate depends on the previous hidden state $\mathbf{h}^{(t-1)}$, and the current input $\mathbf{x}_t$ controls the flow of information. This is reminiscent of long short-term memory (LSTM) units (Hochreiter and Schmidhuber, 1997). For details about this unit, we refer the reader to (Cho et al., 2014) and Fig. 1 (b). For the remainder of this paper, we always use this new activation function.

2.2 Gated Recursive Convolutional Neural Network

Besides RNNs, another natural approach to dealing with variable-length sequences is to use a recursive convolutional neural network where the parameters at each level are shared through the whole network (see Fig. 2 (a)). In this section, we introduce a binary convolutional neural network whose weights are recursively applied to the input sequence until it outputs a single fixed-length vector. In addition to a usual convolutional architecture, we propose to use the previously mentioned gating mechanism, which allows the recursive network to learn the structure of the source sentences on the fly.

Let $x = (\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_T)$ be an input sequence, where $\mathbf{x}_t \in \mathbb{R}^d$. The proposed gated recursive convolutional neural network (grConv) consists of four weight matrices $\mathbf{W}^l$, $\mathbf{W}^r$, $\mathbf{G}^l$ and $\mathbf{G}^r$. At each recursion level $t \in [1, T-1]$, the activation of the j -th hidden unit $h_j^{(t)}$ is computed by

$$h_j^{(t)} = \omega_c \tilde{h}_j^{(t)} + \omega_l h_{j-1}^{(t-1)} + \omega_r h_j^{(t-1)}, \quad (1)$$

where ω_c , ω_l and ω_r are the values of a gater that sum to 1. The hidden unit is initialized as

$$h_j^{(0)} = \mathbf{U} \mathbf{x}_j,$$

where $\mathbf{U}$ projects the input into a hidden space.

我们的分析表明，随着源句子长度的增加，神经机器翻译模型的性能会迅速下降。此外，我们还发现词汇量对翻译性能有着显著影响。尽管如此，从质量层面来看，这两种模型大多数时候都能生成正确的译文。而且，新提出的grConv模型无需监督即可学习源语言中的某种句法结构。

2 面向变长序列的神经网络

在本节中，我们将介绍两种能够处理变长序列的神经网络类型，即循环神经网络以及本文提出的带门控结构的递归卷积神经网络。

2.1 带门控隐藏神经元的循环神经网络




图1: (a)循环神经网络以及(b)能够自适应地遗忘与记忆的隐藏单元的图形示意图。

循环神经网络 (RNN, 见图1) 通过随时间保持一个隐藏状态 $\mathbf{h}$ 来处理变长序列 $x = (\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_T)$ 。在每个时间步 t ，隐藏状态 $\mathbf{h}^{(t)}$ 会通过以下方式得到更新。

$$\mathbf{h}^{(t)} = f(\mathbf{h}^{(t-1)}, \mathbf{x}_t),$$

其中 f 为激活函数。通常 f 的操作较为简单，仅需对输入向量进行线性变换、求和，再应用逐元素逻辑斯蒂sigmoid函数即可。

循环神经网络可通过学习后续输入 $p(\mathbf{x}_{t+1} | \mathbf{x}_t, \dots, \mathbf{x}_1)$ 的分布，从而有效学习变长序列上对应的联合概率分布。例如，在由1-of- K 向量构成的序列情况下，这种分布便可由循环神经网络学习得到，其输出即为该分布。

$$p(x_{t,j} = 1 | \mathbf{x}_{t-1}, \dots, \mathbf{x}_1) = \frac{\exp(\mathbf{w}_j \mathbf{h}_{(t)})}{\sum_{j'=1}^K \exp(\mathbf{w}_{j'} \mathbf{h}_{(t)})},$$

对于所有可能的符号 $j = 1, \dots, K$ ，其中 $\mathbf{w}_j$ 为权重矩阵 $\mathbf{W}$ 的各行，由此便可以得出相应的联合概率分布。

$$p(x) = \prod_{t=1}^T p(x_t | x_{t-1}, \dots, x_1).$$

近期，Cho等人2014年的研究提出了一种适用于循环神经网络的新激活函数。该新激活函数在常规的逻辑斯蒂 sigmoid 激活函数的基础上增加了两个门控单元，即重置门 $\mathbf{r}$ 和更新门 $\mathbf{z}$ 。每个门控单元都依赖于之前的隐藏状态 $\mathbf{h}^{(t-1)}$ ，而当前的输入 $\mathbf{x}_t$ 则负责控制信息的传递方向。这一设计与长短期记忆单元 (LSTM) 的机制颇为相似 (Hochreiter与Schmidhuber, 1997)。关于该单元的更多细节，可参考Cho等人2014年的研究以及图1(b)。在本文的后续内容中，我们将始终使用这种新的激活函数。

2.2 带门控的递归卷积神经网络

除了循环神经网络之外，另一种处理变长序列的常见方法就是采用递归卷积神经网络，这类网络的各层参数会在整个网络中共享 (见图 2(a))。在本节中，我们介绍一种二进制卷积神经网络，其权重会通过递归方式逐步作用于输入序列，最终输出一个固定长度的向量。在常规的卷积架构基础上，我们还引入了前文提到的门控机制，这使得递归网络能够动态学习源句子的结构。

设 $x = (\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_T)$ 为一个输入序列，其中 $\mathbf{x}_t \in \mathbb{R}^d$ 。所提出的门控递归卷积神经网络 (grConv) 由四个权重矩阵 $\mathbf{W}^l$ 、 $\mathbf{W}^r$ 、 $\mathbf{G}^l$ 以及 $\mathbf{G}^r$ 构成。在每一个递归层级 $t \in [1, T-1]$ 上，第 j 个隐藏单元 $h_j^{(t)}$ 的激活值都是通过以下方式计算得出的：

$$h_j^{(t)} = \omega_c \tilde{h}_j^{(t)} + \omega_l h_{j-1}^{(t-1)} + \omega_r h_j^{(t-1)}, \quad (1)$$

其中 ω_c 、 ω_l 和 ω_r 是某个门控单元的各个数值，这些数值之和为1。该隐藏单元的初始值设定为

$$h_j^{(0)} = \mathbf{U} \mathbf{x}_j,$$

其中， $\mathbf{U}$ 矩阵会将输入数据映射到隐藏空间中。




Figure 2: The graphical illustration of (a) the recursive convolutional neural network and (b) the proposed gated unit for the recursive convolutional neural network. (c–d) The example structures that may be learned with the proposed gated unit.

The new activation $\tilde{h}_j^{(t)}$ is computed as usual:

$$\tilde{h}_j^{(t)} = \phi \left(\mathbf{W}^l h_{j-1}^{(t)} + \mathbf{W}^r h_j^{(t)} \right),$$

where ϕ is an element-wise nonlinearity.

The gating coefficients ω 's are computed by

$$\begin{bmatrix} \omega_c \\ \omega_l \\ \omega_r \end{bmatrix} = \frac{1}{Z} \exp \left(\mathbf{G}^l h_{j-1}^{(t)} + \mathbf{G}^r h_j^{(t)} \right),$$

where $\mathbf{G}^l, \mathbf{G}^r \in \mathbb{R}^{3 \times d}$ and

$$Z = \sum_{k=1}^3 \left[\exp \left(\mathbf{G}^l h_{j-1}^{(t)} + \mathbf{G}^r h_j^{(t)} \right) \right]_k.$$

According to this activation, one can think of the activation of a single node at recursion level t as a choice between either a new activation computed from both left and right children, the activation from the left child, or the activation from the right child. This choice allows the overall structure of the recursive convolution to change adaptively with respect to an input sample. See Fig. 2 (b) for an illustration.

In this respect, we may even consider the proposed grConv as doing a kind of unsupervised parsing. If we consider the case where the gating unit makes a hard decision, i.e., ω follows an 1-of-K coding, it is easy to see that the network adapts to the input and forms a tree-like structure (See Fig. 2 (c–d)). However, we leave the further investigation of the structure learned by this model for future research.

3 Purely Neural Machine Translation

3.1 Encoder–Decoder Approach

The task of translation can be understood from the perspective of machine learning as learning the




Figure 3: The encoder–decoder architecture

conditional distribution $p(f | e)$ of a target sentence (translation) f given a source sentence e . Once the conditional distribution is learned by a model, one can use the model to directly sample a target sentence given a source sentence, either by actual sampling or by using a (approximate) search algorithm to find the maximum of the distribution.

A number of recent papers have proposed to use neural networks to directly learn the conditional distribution from a bilingual, parallel corpus (Kalchbrenner and Blunsom, 2013; Cho et al., 2014; Sutskever et al., 2014). For instance, the authors of (Kalchbrenner and Blunsom, 2013) proposed an approach involving a convolutional n -gram model to extract a fixed-length vector of a source sentence which is decoded with an inverse convolutional n -gram model augmented with an RNN. In (Sutskever et al., 2014), an RNN with LSTM units was used to encode a source sentence and starting from the last hidden state, to decode a target sentence. Similarly, the authors of (Cho et al., 2014) proposed to use an RNN to encode and decode a pair of source and target phrases.

At the core of all these recent works lies an encoder–decoder architecture (see Fig. 3). The encoder processes a variable-length input (source sentence) and builds a fixed-length vector representation (denoted as $\mathbf{z}$ in Fig. 3). Conditioned on




图2: (a)递归卷积神经网络以及(b)为该网络设计的门控单元的图形展示; (c–d)使用所提出的门控单元可学习到的示例结构。

新的激活值 $\tilde{h}_j^{(t)}$ 仍按照常规方式计算:

$$\tilde{h}_j^{(t)} = \phi \left(\mathbf{W}^l h_{j-1}^{(t)} + \mathbf{W}^r h_j^{(t)} \right),$$

其中 ϕ 表示逐元素非线性运算。

这些门控系数 ω 是通过特定方法计算得出的。

$$\begin{bmatrix} \omega_c \\ \omega_l \\ \omega_r \end{bmatrix} = \frac{1}{Z} \exp \left(\mathbf{G}^l h_{j-1}^{(t)} + \mathbf{G}^r h_j^{(t)} \right),$$

其中 $\mathbf{G}^l, \mathbf{G}^r \in \mathbb{R}^{3 \times d}$ 以及……

$$Z = \sum_{k=1}^3 \left[\exp \left(\mathbf{G}^l h_{j-1}^{(t)} + \mathbf{G}^r h_j^{(t)} \right) \right]_k.$$

根据这种激活机制, 可以将递归层级 t 处单个节点的激活值视为三种可能选择之一: 由左右子节点共同计算得到的新激活值、左子节点的激活值, 或是右子节点的激活值。这样的选择机制使得递归卷积的整体结构能够根据输入样本自适应地发生变化。相关示意图见图 2(b)。

从这个角度来看, 我们甚至可以将所提出的 grConv 模型视作一种无监督解析方式。在门控单元做出确定性决策的情况下, 即采用 1-of-K 编码方案 ω 时, 不难发现该神经网络会随之调整并形成树状结构 (参见图 2(c–d))。不过, 关于该模型所学习到的结构的具体细节, 我们暂留待后续研究进一步探讨。

3 纯神经网络机器翻译

3.1 编码器-解码器架构

从机器学习的视角来看, 翻译任务可以被理解为学习某种条件分布。




图3: 编码器-解码器架构

具体而言, 就是学习在给定源句子的情况下目标句子 (即译文) f 的 $p(f | e)$ 条件分布 f 。一旦模型学会了这种条件分布, 就可以利用它直接根据源句子生成目标句子, 要么通过直接采样, 要么借助 (近似的) 搜索算法来找到该分布中的最大值。

近期有许多论文提出利用神经网络直接从双语平行语料库中学习条件分布 (Kalchbrenner和Blunsom, 2013; Cho等人, 2014; Sutskever等人, 2014)。例如, (Kalchbrenner和Blunsom, 2013)的作者提出了一种方法, 该方法借助卷积 n -文法模型来提取源句子的固定长度向量, 再通过结合了 RNN 的逆卷积 n -文法模型对这一向量进行解码。在 (Sutskever等人, 2014) 的研究中, 则采用带有 LSTM 单元的 RNN 来对源句子进行编码, 并从最后一个隐藏状态开始解码目标句子。同样地, (Cho等人, 2014)的作者也提出使用 RNN 来对一对源短语和目标短语分别进行编码与解码。

所有这些近期研究的核心都在于编码器-解码器架构 (见图 3)。该架构中的编码器会处理变长输入——即源句子, 并将其转换为固定长度的向量表示形式 (在图 3 中用 $\mathbf{z}$ 表示)。在得到这一编码表示后

the encoded representation, the decoder generates a variable-length sequence (target sentence).

Before (Sutskever et al., 2014) this encoder–decoder approach was used mainly as a part of the existing statistical machine translation (SMT) system. This approach was used to re-rank the n -best list generated by the SMT system in (Kalchbrenner and Blunsom, 2013), and the authors of (Cho et al., 2014) used this approach to provide an additional score for the existing phrase table.

In this paper, we concentrate on analyzing the direct translation performance, as in (Sutskever et al., 2014), with two model configurations. In both models, we use an RNN with the gated hidden unit (Cho et al., 2014), as this is one of the only options that does not require a non-trivial way to determine the target length. The first model will use the same RNN with the gated hidden unit as an encoder, as in (Cho et al., 2014), and the second one will use the proposed gated recursive convolutional neural network (grConv). We aim to understand the inductive bias of the encoder–decoder approach on the translation performance measured by BLEU.

4 Experiment Settings

4.1 Dataset

We evaluate the encoder–decoder models on the task of English-to-French translation. We use the bilingual, parallel corpus which is a set of 348M selected by the method in (Axelrod et al., 2011) from a combination of Europarl (61M words), news commentary (5.5M), UN (421M) and two crawled corpora of 90M and 780M words respectively.¹ We did not use separate monolingual data. The performance of the neural machine translation models was measured on the news-test2012, news-test2013 and news-test2014 sets (3000 lines each). When comparing to the SMT system, we use news-test2012 and news-test2013 as our development set for tuning the SMT system, and news-test2014 as our test set.

Among all the sentence pairs in the prepared parallel corpus, for reasons of computational efficiency we only use the pairs where both English and French sentences are at most 30 words long to train neural networks. Furthermore, we use only the 30,000 most frequent words for both English

and French. All the other rare words are considered unknown and are mapped to a special token ([UNK]).

4.2 Models

We train two models: The RNN Encoder–Decoder (RNNenc)(Cho et al., 2014) and the newly proposed gated recursive convolutional neural network (grConv). Note that both models use an RNN with gated hidden units as a decoder (see Sec. 2.1).

We use minibatch stochastic gradient descent with AdaDelta (Zeiler, 2012) to train our two models. We initialize the square weight matrix (transition matrix) as an orthogonal matrix with its spectral radius set to 1 in the case of the RNNenc and 0.4 in the case of the grConv. tanh and a rectifier ($\max(0, x)$) are used as the element-wise nonlinear functions for the RNNenc and grConv respectively.

The grConv has 2000 hidden neurons, whereas the RNNenc has 1000 hidden neurons. The word embeddings are 620-dimensional in both cases.² Both models were trained for approximately 110 hours, which is equivalent to 296,144 updates and 846,322 updates for the grConv and RNNenc, respectively.³

4.2.1 Translation using Beam-Search

We use a basic form of beam-search to find a translation that maximizes the conditional probability given by a specific model (in this case, either the RNNenc or the grConv). At each time step of the decoder, we keep the s translation candidates with the highest log-probability, where $s = 10$ is the beam-width. During the beam-search, we exclude any hypothesis that includes an unknown word. For each end-of-sequence symbol that is selected among the highest scoring candidates the beam-width is reduced by one, until the beam-width reaches zero.

The beam-search to (approximately) find a sequence of maximum log-probability under RNN was proposed and used successfully in (Graves, 2012) and (Boulanger-Lewandowski et al., 2013). Recently, the authors of (Sutskever et al., 2014) found this approach to be effective in purely neural machine translation based on LSTM units.

²In all cases, we train the whole network including the word embedding matrix.

³The code will be available online, should the paper be accepted.

解码器便以此编码表示为条件, 生成对应的变长序列, 也就是目标句子。

在 (Sutskever等人2014年的研究) 之前, 这种编码器-解码器架构主要被用作现有统计机器翻译系统的一部分。正如 (Kalchbrenner和Blunsom2013年的研究) 所示, 该架构曾被用来对统计机器翻译系统生成的 n 个最佳候选项进行重新排序; 而 (Cho等人2014年的研究) 的作者则利用它为现有的短语表提供额外的评分依据。

本文与 (Sutskever等人2014年的研究) 类似, 重点分析两种模型配置下的直接翻译性能。在这两种模型中, 我们都采用了带门控隐藏单元的循环神经网络 (Cho等人2014年的研究), 因为这是为数不多的无需复杂方法即可确定目标文本长度的选项之一。第一个模型会像 (Cho等人2014年的研究) 那样, 使用同样的带门控隐藏单元的RNN作为编码器; 而第二个模型则会采用我们提出的带门控的递归卷积神经网络 (grConv)。我们的目标是探究编码器-解码器架构对以BLEU分数衡量的翻译性能所具有的归纳偏差作用。

4 实验设置

4.1 数据集

我们针对英法互译任务对编码器-解码器架构的模型进行了评估。所使用的双语平行语料库共有3.48亿单词, 这些语料是通过(Axelrod等人, 2011)提出的方法, 从Europarl语料库 (6100万单词)、新闻评论语料库 (550万单词)、联合国语料库 (4.21亿单词), 以及另外两个分别包含9000万单词和7.8亿单词的爬取语料库中筛选整合而成的。¹ 我们并未使用单独的单语数据。这些神经机器翻译模型的性能是在 news-test2012、news-test2013和news-test2014这三个测试集上测量的, 每个测试集包含3000行文本。在与传统统计机器翻译系统进行比较时, 我们会将 news-test2012和news-test2013作为调整该系统的开发集, 而将news-test2014作为测试集。

在准备好的平行语料库中的所有句子对中, 出于计算效率的考虑, 我们仅选用英语和法语句子长度均不超过30个单词的那些对来训练神经网络。此外, 我们仅使用英语和法语中最常见的30,000个单词。

¹所有数据均可从http://www-lium.univ-lemans.fr/~schwenk/cslm_joint_paper/下载。

其余所有罕见的单词都被视为未知词, 并被映射到一个特殊的标记([UNK])上。

4.2 模型

我们共训练了两种模型: 基于RNN编解码器架构的RNNenc模型 (Cho等人2014年的研究) 以及新提出的带门控的递归卷积神经网络grConv模型。需要注意的是, 这两种模型的解码器均采用带有门控功能的隐藏单元的循环神经网络 (详见2.1节)。

在训练这两种模型时, 我们采用了结合AdaDelta算法的小批量随机梯度下降方法 (Zeiler, 2012年)。对于RNNenc模型, 其方阵权重矩阵即转移矩阵被初始化为正交矩阵, 且其谱半径设为1; 而对于grConv模型, 则该谱半径被设为4.。此外, RNNenc模型采用双曲正切函数作为逐元素非线性函数, 而grConv模型则采用整流函数 ($\max(0, x)$)作为相应的非线性函数。

grConv模型拥有2000个隐藏神经元, 而RNNenc模型则拥有1000个隐藏神经元。在这两种模型中, 所使用的词嵌入维度均为620维。² 这两种模型分别经过了大约110小时的训练, 相应地, RNNenc模型完成了296,144次参数更新, 而grConv模型则完成了846,322次参数更新。³

4.2.1 使用束搜索算法进行译文生成

我们采用一种基础的束搜索形式, 来寻找能够最大化特定模型所给出的条件概率的译文 (在本例中, 该模型为RNNenc模型或grConv模型)。在解码器的每个时间步中, 我们会保留对数概率最高的 s 译文候选项, 其中 $s = 10$ 即为束宽。在束搜索过程中, 凡是包含未知词汇的假设都会被排除。每当从得分最高的候选项中选出一个序列结束标记时, 束宽就会减少1, 直至束宽降为零。

在循环神经网络框架下, 人们提出了束搜索算法, 用以 (近似地) 找出对数概率最大的序列, 并且该算法已在(Graves, 2012)与(Boulanger-Lewandowski等人, 2013)的研究中得到成功应用。近期, Sutskever等人2014年的研究指出, 这种方法在基于LSTM单元的纯神经机器译文系统中同样具有良好效果。

²在所有情况下, 我们都会对包括词嵌入矩阵在内的整个神经网络进行训练。³如果论文被接收, 相关代码将会在网上公布。

¹All the data can be downloaded from http://www-lium.univ-lemans.fr/~schwenk/cslm_joint_paper/.

	Model	Development	Test
All	RNNenc	13.15	13.92
	grConv	9.97	9.97
	Moses	30.64	33.30
	Moses+RNNenc*	31.48	34.64
	Moses+LSTM ^o	32	35.65
No UNK	RNNenc	21.01	23.45
	grConv	17.19	18.22
	Moses	32.77	35.63

(a) All Lengths

	Model	Development	Test
All	RNNenc	19.12	20.99
	grConv	16.60	17.50
	Moses	28.92	32.00
	RNNenc	24.73	27.03
No UNK	grConv	21.74	22.94
	Moses	32.20	35.40

(b) 10–20 Words

Table 1: BLEU scores computed on the development and test sets. The top three rows show the scores on all the sentences, and the bottom three rows on the sentences having no unknown words. (★) The result reported in (Cho et al., 2014) where the RNNenc was used to score phrase pairs in the phrase table. (o) The result reported in (Sutskever et al., 2014) where an encoder–decoder with LSTM units was used to re-rank the n -best list generated by Moses.

When we use the beam-search to find the k best translations, we do not use a usual log-probability but one normalized with respect to the length of the translation. This prevents the RNN decoder from favoring shorter translations, behavior which was observed earlier in, e.g., (Graves, 2013).

5 Results and Analysis

5.1 Quantitative Analysis

In this paper, we are interested in the properties of the neural machine translation models. Specifically, the translation quality with respect to the length of source and/or target sentences and with respect to the number of words unknown to the model in each source/target sentence.

First, we look at how the BLEU score, reflecting the translation performance, changes with respect to the length of the sentences (see Fig. 4 (a)–(b)). Clearly, both models perform relatively well on short sentences, but suffer significantly as the length of the sentences increases.

We observe a similar trend with the number of unknown words, in Fig. 4 (c). As expected, the performance degrades rapidly as the number of unknown words increases. This suggests that it will be an important challenge to increase the size of vocabularies used by the neural machine translation system in the future. Although we only present the result with the RNNenc, we observed similar behavior for the grConv as well.

In Table 1 (a), we present the translation performances obtained using the two models along with the baseline phrase-based SMT system.⁴ Clearly

⁴We used Moses as a baseline, trained with additional

the phrase-based SMT system still shows the superior performance over the proposed purely neural machine translation system, but we can see that under certain conditions (no unknown words in both source and reference sentences), the difference diminishes quite significantly. Furthermore, if we consider only short sentences (10–20 words per sentence), the difference further decreases (see Table 1 (b)).

Furthermore, it is possible to use the neural machine translation models together with the existing phrase-based system, which was found recently in (Cho et al., 2014; Sutskever et al., 2014) to improve the overall translation performance (see Table 1 (a)).

This analysis suggests that the current neural translation approach has its weakness in handling long sentences. The most obvious explanatory hypothesis is that the fixed-length vector representation does not have enough capacity to encode a long sentence with complicated structure and meaning. In order to encode a variable-length sequence, a neural network may “sacrifice” some of the important topics in the input sentence in order to remember others.

This is in stark contrast to the conventional phrase-based machine translation system (Koehn et al., 2003). As we can see from Fig. 5, the conventional system trained on the same dataset (with additional monolingual data for the language model) tends to get a higher BLEU score on longer sentences.

In fact, if we limit the lengths of both the source monolingual data for a 4-gram language model.

	模型	开发	Test
All	RNNenc模型	13.15	13.92
	grConv模型	9.97	9.97
	Moses模型	30.64	33.30
	Moses模型+RNNenc模型*	31.48	34.64
	Moses模型+LSTM ^o	32	35.65
No UNK	RNNenc模型	21.01	23.45
	grConv模型	17.19	18.22
	Moses模型	32.77	35.63

(a) 所有长度

	模型	开发	Test
All	RNNenc模型	19.12	20.99
	grConv模型	16.60	17.50
	Moses模型	28.92	32.00
	RNNenc模型	24.73	27.03
No UNK	grConv模型	21.74	22.94
	Moses模型	32.20	35.40

(b) 10–20个单词

表1: 在开发集与测试集上计算得到的BLEU分数。最上面的三行显示了所有句子的分数，最下面的三行则显示了不含未知单词的句子的分数。(★)该结果源自(Cho等人2014年的研究)，当时使用RNNenc模型对短语表中的短语对进行评分。(o)另一个结果来自(Sutskever等人2014年的研究)，他们采用了带有LSTM单元的编码器-解码器架构，对Moses模型生成的 n 个最佳候选项重新排序后得出相应分数。

当我们使用束搜索算法来寻找 k 最优的译文时，所采用的并非常规的对数概率，而是经过译文长度归一化处理后的对数概率。这样做可以避免循环神经网络解码器倾向于选择较短的译文，而这种倾向在之前的研究，例如(Graves, 2013)中就已经被观察到了。

5 结果与分析

5.1 定量分析

在本文中，我们主要研究神经机器翻译模型的特性。具体而言，就是探讨译文质量如何随源文本和/或目标句子的长度变化，以及如何随每个源文本/目标句子中模型无法识别的单词数量变化。

首先，我们分析了反映译文质量的BLEU分数随句子长度的变化情况（见图4的(a)–(b)）。显然，两种模型在短句子上的表现都相当不错，但随着句子长度的增加，其性能会出现显著下降。

在图4的(c)中，我们可以观察到未知单词数量也与此趋势相似。正如预期，随着未知单词数量的增加，模型性能会迅速恶化。这表明，未来如何扩大神经机器翻译系统所使用的词汇表规模将是一个重要的挑战。虽然此处仅展示了RNNenc模型的结果，但我们发现grConv模型也呈现出类似的趋势。

在表1(a)中，我们展示了采用这两种模型以及作为基线的基于短语的统计机器翻译系统所获得的机器翻译性能指标⁴。显然，

⁴我们以Moses模型作为基准，并采用了额外的训练方式。

基于短语的统计机器翻译系统在性能上依然优于所提出的纯神经网络机器翻译系统，但我们可以看到，在某些特定条件下（即源文本和参考文本均不含未知单词时），两者之间的差距会显著缩小。此外，如果仅考虑短句（每句10至20个单词），这种差距还会进一步减小（详见表1(b)）。

此外，最近有研究指出（参见Cho等人2014年的研究以及Sutskever等人2014年的研究），可以将神经机器翻译模型与现有的基于短语的系统结合使用，从而提升整体的译文质量（见表1的(a)）。

这项分析表明，目前的机器翻译神经网络方法在处理长句子时存在缺陷。最显而易见的解释性假设是，固定长度的向量表示方式缺乏足够的容量来编码结构复杂、含义繁多的长句子。为了解码变长序列，神经网络可能会“牺牲”输入句子中的一些重要信息，以便记住其他内容。

这与传统的基于短语的机器翻译系统（Koehn等人，2003年）形成了鲜明对比。从图5可以看出，基于相同数据集训练的传统系统（该语言模型还使用了额外的单语数据）在处理长句子时往往能获得更高的BLEU分数。

实际上，如果我们限制源文本和单语数据的长度。即为4-gram语言模型准备的单语数据。

Source	She explained her new position of foreign affairs and security policy representative as a reply to a question: "Who is the European Union? Which phone number should I call?"; i.e. as an important step to unification and better clarity of Union’s policy towards countries such as China or India.
Reference	Elle a expliqué le nouveau poste de la Haute représentante pour les affaires étrangères et la politique de défense dans le cadre d’une réponse à la question: "Qui est qui à l’Union européenne?" ”A quel numéro de téléphone dois-je appeler?", donc comme un pas important vers l’unicité et une plus grande lisibilité de la politique de l’Union face aux états, comme est la Chine ou bien l’Inde.
RNNEnc	Elle a décrit sa position en matière de politique étrangère et de sécurité ainsi que la politique de l’Union européenne en matière de gouvernance et de démocratie .
grConv	Elle a expliqué sa nouvelle politique étrangère et de sécurité en réponse à un certain nombre de questions : ”Qu’est-ce que l’Union européenne ? ” .
Moses	Elle a expliqué son nouveau poste des affaires étrangères et la politique de sécurité représentant en réponse à une question: "Qui est l’Union européenne? Quel numéro de téléphone dois-je appeler?"; c’est comme une étape importante de l’unification et une meilleure lisibilité de la politique de l’Union à des pays comme la Chine ou l’Inde .

Source	The investigation should be complete by the end of the year when the findings will be presented to Deutsche Bank’s board of managing directors - with recommendations for action.
Reference	L’examen doit être terminé d’ici la fin de l’année, ensuite les résultats du conseil d’administration de la Deutsche Bank doivent être présentés - avec recommandation, d’ habitude.
RNNEnc	L’étude devrait être terminée à la fin de l’ année, lorsque les conclusions seront présentées au conseil d’administration de la Deutsche Bank, conseil d’association avec des mesures.
grConv	L’enquête devrait être terminée à la fin de l’année où les conclusions seront présentées par le conseil d’administration de la BCE à la direction des recommandations.
Moses	L’enquête devrait être terminé d’ici la fin de l’année lorsque les résultats seront présentés à la Deutsche Bank conseil des directeurs généraux - avec des recommandations .

Source	And there are thorny mechanical questions that must be resolved during that time, like how to balance the state’s mandate of "adequate access" to licensed marijuana with its prohibitions on cannabis businesses within 1,000 feet of a school, park, playground or child care center.
Reference	Pendant ce temps, des questions pratiques restent en suspens: comment équilibrer le mandat de l’état qui garantit un accès approprié à la marijuana agréée et interdit l’installation de commerces de vente de cannabis dans un rayon de 30 km autour d’une école, d’un parc, d’un terrain de jeu ou d’une crèche.
RNNEnc	Il y a des questions préventives qui se posent quant à l’équilibre des droits de l’enfant dans les limites d’une entreprise de collecte de sang.
grConv	De façon générale, il y a des raisons de sécurité pour que les entreprises aient accès à des milliers de centres de pêche, d’eau ou de recherche.
Moses	Et il y a des problèmes mécaniques complexes qui doivent être résolues au cours de cette période, comme la manière d’équilibrer le mandat de "l'accès adéquat" permis de marijuana avec l’interdiction du cannabis aux entreprises de 1000 pieds d’une école de jeu ou de parc, le service de garde.

(a) Long Sentences

Source	There is still no agreement as to which election rules to follow.
Reference	Toutefois il n’existe toujours pas d’accord selon quel règlement de vote il faut procéder.
RNNEnc	Il n’y a pas encore d’accord sur les règles électorales.
grConv	Il n’y a pas encore d’accord sur la question des élections à suivre.
Moses	Il y a toujours pas d’accord sur l’élection des règles à suivre.

Source	Many of these ideas may have been creative, but they didn’t necessarily work.
Reference	Beaucoup de ces idées étaient créatives mais elles n’ont pas forcément fonctionné.
RNNEnc	Bon nombre de ces idées ont peut-être été créatrices, mais elles ne s’appliquaient pas nécessairement.
grConv	Beaucoup de ces idées peuvent être créatives, mais elles n’ont pas fonctionné.
Moses	Beaucoup de ces idées ont pu être créatif, mais ils n’ont pas nécessairement.

Source	There is a lot of consensus between the Left and the Right on this subject.
Reference	C’est qu’il y a sur ce sujet un assez large consensus entre gauche et droite.
RNNEnc	Il existe beaucoup de consensus entre la gauche et le droit à la question.
grConv	Il y a un consensus entre la gauche et le droit sur cette question.
Moses	Il y a beaucoup de consensus entre la gauche et la droite sur ce sujet.

Source	According to them, one can find any weapon at a low price right now.
Reference	Selon eux, on peut trouver aujourd’hui à Moscou n’importe quelle arme pour un prix raisonnable.
RNNEnc	Selon eux, on peut se trouver de l’arme à un prix trop bas.
grConv	En tout cas, ils peuvent trouver une arme à un prix très bas à la fois.
Moses	Selon eux, on trouve une arme à bas prix pour l’instant.

(b) Short Sentences

Table 2: The sample translations along with the source sentences and the reference translations.

源文本	她将自己的新职务——外交与安全政策代表解释为对某一问题的回应。问题：“什么是欧洲联盟？我应该拨打哪个电话号码？”；也就是说，作为重要的一步旨在让联合国针对中国或印度等国家的政策更加统一且清晰明了。
参考文本	她解释了新设立的欧盟外交与政策高级代表一职及其职责。作为对‘谁是欧盟内的谁？应该拨打哪个号码’这一问题的回应，我们在此进行相关说明。也就是说，这相当于迈向统一性与更高可读性的重要一步。涉及欧盟针对中国和印度等国家的政策。
RNNenc	它明确了该国在外交政策、安全政策以及欧盟政策方面的立场。也就是欧盟在治理与民主方面的相关政策。
grConv模型	她针对诸多问题，阐述了自己的新外交政策与安全政策。：“什么是欧洲联盟？”
Moses模型	她说明了自己担任的新外交事务职务以及相应的安全政策。这是对一个问题“谁是欧洲联盟？我应该拨打哪个电话号码？”的回答。这堪称是实现统一并提升欧盟政策可读性的一个重要‘阶段。包括中国和印度在内的国家。

参考文本	该项调查应于今年年底前完成，届时会将调查结果呈报给相关方。德意志银行管理董事会——附有相应行动建议。
参考文本	该考试必须在今年年底前完成。，随后是相关董事会的决议结果。通常情况下，德意志银行的报告也会一并提交，其中还会包含相应的建议意见。
RNNenc	这项研究应在今年年底前结束，届时会将研究结论提交给德意志银行的董事会。即德意志银行的董事会。，协会建议需配套相应措施。
grConv模型	该项调查应于当年年底前完成，届时委员会将提交调查结果。欧洲央行管理层会将相关建议传达给相关部门。
Moses模型	调查预计在当年年底前结束，届时调查结果将呈报给德国方面。董事会咨询小组——附有相关建议。

源文本	此外，在此期间还有许多棘手的机械问题需要解决，比如如何平衡——在允许使用持牌大麻的同时，又对大麻种植实行禁令，这种状况该如何调和？距离学校、公园、游乐场或托儿中心1,000英尺以内的企业。
参考文本	与此同时，一些实际问题依然悬而未决：如何‘平衡’国家的职责，以确保对合法种植的大麻的适当获取，同时禁止在校园、公园、游乐场或教堂周边30公里范围内设立大麻销售点。即确保能够‘以适当方式’获取合法种植的大麻，同时禁止在校园、公园、游乐场或教堂周边30公里范围内设立大麻销售店。也就是禁止在校园、公园、游乐场或教堂周边30公里范围内开设大麻销售店铺。
RNNenc模型	关于在血站运营范畴内如何‘平衡儿童权益’的问题，也存在一些潜在的疑问。即与血站相关的运营范畴。
grConv模型	从更广义的角度来看，出于安全考虑，企业有必要能够访问成千上万的渔业、水域或研究机构。渔业、水上活动或研究基地。
Moses模型	此外，在此期间还有许多复杂的机械问题需要得到解决。例如，如何在允许大麻的‘平等获取’政策与相关禁令之间找到平衡。对于那些拥有1000英尺面积的赌场或游乐场，以及相关安保服务的企业而言，大麻的使用情况如何？

(a) 长句子

源文本	目前仍未能就应遵循何种选举规则达成一致意见。
参考文本	不过，关于应当依据哪项投票规定来开展选举，至今依然没有共识。
RNNenc模型	目前对于选举规则尚无统一共识。
grConv模型	关于后续选举的相关事宜，目前也尚未达成一致意见。
Moses模型	对于后续选举的候选人选拔问题，至今依然没有统一的标准。

源文本	这些想法中有许多或许颇具创意，但并不一定能够真正发挥作用。
参考文本	这些想法中有很多或许具有创造性，但它们并不一定能够成功实现。
RNNenc模型	很多这样的想法也许具备创造性，但却未必必然适用。
grConv模型	这些想法中有许多或许颇具创意，但并未真正发挥作用。
Moses模型	这些想法中有许多或许具有创意，但他们并不一定能成功实现。

源文本	在这个问题上，左派与右派之间存在着相当多的共识。
参考文本	在这一点上，左翼与右翼之间存在相当广泛的共识。
RNNenc	关于这个问题，左翼与右翼之间有着诸多共识`。
grConv	对于该问题，左翼与右翼同样存在共识。
Moses模型	在这一点上，左派与右派之间存在广泛的共识。

源文本	据他们所说，目前任何武器都能以较低的价格买到。
参考文本	据他们所言，如今在莫斯科可以以合理的价格买到‘任何武器。
RNNenc模型	据他们所说，有可能以过低的价格找到武器`。
grConv模型	无论如何，他们能够同时以极低的价格‘找到武器`。
Moses模型	据他们所述，目前可以以较低的价格买到武器`。

(b) 短句

表2：示例译文以及对应的源句子与参考译文。




Figure 4: The BLEU scores achieved by (a) the RNNenc and (b) the grConv for sentences of a given length. The plot is smoothed by taking a window of size 10. (c) The BLEU scores achieved by the RNN model for sentences with less than a given number of unknown words.

sentence and the reference translation to be between 10 and 20 words and use only the sentences with no unknown words, the BLEU scores on the test set are 27.81 and 33.08 for the RNNenc and Moses, respectively.

Note that we observed a similar trend even when we used sentences of up to 50 words to train these models.

5.2 Qualitative Analysis

Although BLEU score is used as a de-facto standard metric for evaluating the performance of a machine translation system, it is not the perfect metric (see, e.g., (Song et al., 2013; Liu et al., 2011)). Hence, here we present some of the actual translations generated from the two models, RNNenc and grConv.

In Table. 2 (a)–(b), we show the translations of some randomly selected sentences from the development and test sets. We chose the ones that have no unknown words. (a) lists long sentences (longer than 30 words), and (b) short sentences (shorter than 10 words). We can see that, despite the difference in the BLEU scores, all three models (RNNenc, grConv and Moses) do a decent job at translating, especially, short sentences. When the source sentences are long, however, we notice the performance degradation of the neural machine translation models.

Additionally, we present here what type of structure the proposed gated recursive convolutional network learns to represent. With a sample sentence “Obama is the President of the United States”, we present the parsing structure learned by the grConv encoder and the generated translations, in Fig. 6. The figure suggests that the grConv extracts the vector representation of the sen-




Figure 5: The BLEU scores achieved by an SMT system for sentences of a given length. The plot is smoothed by taking a window of size 10. We use the solid, dotted and dashed lines to show the effect of different lengths of source, reference or both of them, respectively.

tence by first merging “of the United States” together with “is the President of” and finally combining this with “Obama is” and “.”, which is well correlated with our intuition.

Despite the lower performance the grConv showed compared to the RNN Encoder–Decoder,⁵ we find this property of the grConv learning a grammar structure automatically interesting and believe further investigation is needed.

6 Conclusion and Discussion

In this paper, we have investigated the property of a recently introduced family of machine trans-

⁵However, it should be noted that the number of gradient updates used to train the grConv was a third of that used to train the RNNenc. Longer training may change the result, but for a fair comparison we chose to compare models which were trained for an equal amount of time. Neither model was trained to convergence.




图4: 对于固定长度的句子, (a) RNNenc模型与(b) grConv模型所获得的BLEU分数。该图表通过设置大小为10的窗口大小对数据进行了平滑处理。此外, (c)还展示了当句子中未知单词数量少于特定阈值时, RNN模型所取得的BLEU分数。

在将句子长度限制在10至20个单词之间且仅使用不含未知单词的句子进行测试时, RNNenc模型与Moses模型在测试集上的BLEU分数分别为27.81和33.08。

需要指出的是, 即便使用长度达50个单词的句子来训练这些模型, 我们依然观察到了类似的趋势。

5.2 定性分析

尽管BLEU分数被视作评估机器翻译系统性能的通用标准指标, 但它并非完美的衡量标准 (参见Song等人2013年的研究以及Liu等人2011年的研究)。因此, 在此我们展示了由RNNenc和grConv这两种模型生成的若干实际译文。

表2的(a)项和(b)项分别展示了从开发集和测试集中随机选取的一些句子的译文。我们仅选择了不含未知单词的句子: (a)项列出的是长度超过30个单词的长句子, 而(b)项列出的是长度不足10个单词的短句子。可以看出, 尽管BLEU分数存在差异, 这三种模型——RNNenc、grConv以及Moses模型——在翻译任务中都表现不错, 尤其是在处理短句子时。不过, 当源句子较长时, 这些神经网络驱动的机器翻译模型的性能就会出现下降。

此外, 本文还介绍了所提出的带门控的递归卷积神经网络所学习到的结构类型。以例句“奥巴马是美国的总统”为例, 我们在图6中展示了grConv编码器所学到的句法结构以及生成的译文。该图表明, grConv模型首先将“美国的”与“是总统”合并, 随后再将这一结果与“奥巴马是”以及“。”结合, 从而得到该句子的向量表示, 这一过程与我们先前的直觉高度吻合。




图5: 相同长度的句子在统计机器翻译系统下的BLEU分数分布。该图表通过设置10的窗口大小对数据进行了平滑处理, 其中实线、点线和虚线分别用于展示源文本、参考文本以及两者长度不同时的对应效果。


这种处理方式与我们之前的直觉十分一致: grConv模型首先把“美国的”和“是总统”合并, 然后再把得到的结果与“奥巴马是”以及“。”结合起来, 进而提取出该句子的向量表示。

⁵尽管grConv模型的表现相较于RNN编码器-解码器架构稍逊一筹, 但我们仍认为其能够自动学习语法结构这一特性极具研究价值, 因此认为有必要进一步开展深入探讨。

6 结论与讨论

在本文中, 我们研究了近期出现的一类机器翻译模型的特性。

⁵不过需要指出的是, 用于训练grConv模型的梯度更新次数仅为训练RNNenc模型时的三分之一。虽然延长训练时间可能会改变测试结果, 但为了保证公平比较, 我们选择对比训练时长相同的两种模型。此外, 这两种模型都并未训练至收敛状态。



(a)

Translations

Obama est le Président des États-Unis . (2.06)
 Obama est le président des États-Unis . (2.09)
 Obama est le président des Etats-Unis . (2.61)
 Obama est le Président des Etats-Unis . (3.33)
 Barack Obama est le président des États-Unis . (4.41)
 Barack Obama est le Président des États-Unis . (4.48)
 Barack Obama est le président des Etats-Unis . (4.54)
 L'Obama est le Président des États-Unis . (4.59)
 L'Obama est le président des États-Unis . (4.67)
 Obama est président du Congrès des États-Unis . (5.09)

(b)

Figure 6: (a) The visualization of the grConv structure when the input is “Obama is the President of the United States.”. Only edges with gating coefficient ω higher than 0.1 are shown. (b) The top-10 translations generated by the grConv. The numbers in parentheses are the negative log-probability of the translations.

lation system based purely on neural networks. We focused on evaluating an encoder-decoder approach, proposed recently in (Kalchbrenner and Blunsom, 2013; Cho et al., 2014; Sutskever et al., 2014), on the task of sentence-to-sentence translation. Among many possible encoder-decoder models we specifically chose two models that differ in the choice of the encoder; (1) RNN with gated hidden units and (2) the newly proposed gated recursive convolutional neural network.

After training those two models on pairs of English and French sentences, we analyzed their performance using BLEU scores with respect to the lengths of sentences and the existence of unknown/rare words in sentences. Our analysis revealed that the performance of the neural machine translation suffers significantly from the length of sentences. However, qualitatively, we found that the both models are able to generate correct translations very well.

These analyses suggest a number of future research directions in machine translation purely based on neural networks.

Firstly, it is important to find a way to scale up training a neural network both in terms of computation and memory so that much larger vocabularies for both source and target languages can be used. Especially, when it comes to languages with rich morphology, we may be required to come up with a radically different approach in dealing with


words.

Secondly, more research is needed to prevent the neural machine translation system from underperforming with long sentences. Lastly, we need to explore different neural architectures, especially for the decoder. Despite the radical difference in the architecture between RNN and grConv which were used as an encoder, both models suffer from *the curse of sentence length*. This suggests that it may be due to the lack of representational power in the decoder. Further investigation and research are required.

In addition to the property of a general neural machine translation system, we observed one interesting property of the proposed gated recursive convolutional neural network (grConv). The grConv was found to mimic the grammatical structure of an input sentence without any supervision on syntactic structure of language. We believe this property makes it appropriate for natural language processing applications other than machine translation.

Acknowledgments

The authors would like to acknowledge the support of the following agencies for research funding and computing support: NSERC, Calcul Québec, Compute Canada, the Canada Research Chairs and CIFAR.



(a)

译文

奥巴马是美‘国的总统。(2.06)奥巴马是美‘国的总统。(2.09)奥巴马是美‘国的总统。(2.61)奥巴马是美‘国的总统。(3.33)‘巴拉克·奥巴马是美‘国的总统。(4.41)‘巴拉克·奥巴马是美‘国的总统。(4.48)巴拉克·奥巴马是美‘国的总统。(4.54)那位奥巴马是美‘国的总统。(4.59)‘那位奥巴马是美‘国的总统。(4.67)奥巴马是美‘国国会的首脑。(5.09)

(b)

图6: (a) 当输入为“奥巴马是美国的国家总统。”时, grConv架构的可视化示意图。图中仅显示了门控系数 ω 大于0.1的边。(b) 由grConv生成的排名前10的译文, 括号内的数值为这些译文的负对数概率。

我们基于纯粹由神经网络构成的翻译系统, 重点评估了近期在(Kalchbrenner和Blunsom, 2013; Cho等人2014年的研究; Sutskever等人2014年的研究)中提出的编码器-解码器架构在句对句翻译任务上的表现。在众多可能的编码器-解码器模型中, 我们特意选择了两种在编码器选择上存在差异的模型: (1)带有门控隐藏单元的循环神经网络, 以及(2)新近提出的带门控的递归卷积神经网络。

在用英语和法语句子对来训练这两个模型之后, 我们通过BLEU分数分析了它们的性能, 考察了句子长度以及句子中是否存在未知或罕见单词等因素的影响。分析结果显示, 神经机器翻译系统的性能会因句子长度而大幅下降。不过从质量层面来看, 这两种模型都能很好地生成正确的译文。

这些分析为纯粹基于神经网络的机器翻译领域的未来研究方向指明了若干方向。

首先, 重要的是要找到一种方法, 在计算资源和内存使用方面提升神经网络的训练效率, 从而能够运用规模更大的源文本及目标语言词汇表。尤其是对于那些形态学特征极为复杂的语言, 我们可能有必要采用完全不同的处理方式。

单词。

其次, 需要开展更多研究来避免神经机器翻译系统在处理长句子时表现不佳的问题。最后, 我们需要探索不同的神经网络架构, 尤其是解码器部分。尽管用作编码器的循环神经网络与grConv在架构上存在巨大差异, 但两者都面临着句子长度难题。这表明问题可能出在解码器的表征能力不足上, 因此还需要进一步的调查与研究。

除了具备通用神经机器翻译系统的特性之外, 我们所提出的带门控的递归卷积神经网络(grConv)还展现出另一项有趣的特点: 该模型无需任何关于语言句法结构的监督, 就能模仿输入句子的语法结构。我们认为这一特性使其也适用于机器翻译之外的自然语言处理任务。

致谢

作者们特此感谢以下机构在研究资金及计算资源方面的支持: NSERC、Calcul Québec、Compute Canada、加拿大研究主席计划以及CIFAR项目。

References

Amittai Axelrod, Xiaodong He, and Jianfeng Gao. 2011. Domain adaptation via pseudo in-domain data selection. In *Proceedings of the ACL Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 355–362. Association for Computational Linguistics.

Nicolas Boulanger-Lewandowski, Yoshua Bengio, and Pascal Vincent. 2013. Audio chord recognition with recurrent neural networks. In *ISMIR*.

Kyunghyun Cho, Bart van Merrienboer, Caglar Gulcehre, Fethi Bougares, Holger Schwenk, and Yoshua Bengio. 2014. Learning phrase representations using rnn encoder-decoder for statistical machine translation. In *Proceedings of the Empirical Methods in Natural Language Processing (EMNLP 2014)*, October. to appear.

Alex Graves. 2012. Sequence transduction with recurrent neural networks. In *Proceedings of the 29th International Conference on Machine Learning (ICML 2012)*.

A. Graves. 2013. Generating sequences with recurrent neural networks. *arXiv:1308.0850 [cs.NE]*, August.

S. Hochreiter and J. Schmidhuber. 1997. Long short-term memory. *Neural Computation*, 9(8):1735–1780.

Nal Kalchbrenner and Phil Blunsom. 2013. Two recurrent continuous translation models. In *Proceedings of the ACL Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 1700–1709. Association for Computational Linguistics.

Philipp Koehn, Franz Josef Och, and Daniel Marcu. 2003. Statistical phrase-based translation. In *Proceedings of the 2003 Conference of the North American Chapter of the Association for Computational Linguistics on Human Language Technology - Volume 1*, NAACL ’03, pages 48–54, Stroudsburg, PA, USA. Association for Computational Linguistics.

Chang Liu, Daniel Dahlmeier, and Hwee Tou Ng. 2011. Better evaluation metrics lead to better machine translation. In *Proceedings of the Conference on Empirical Methods in Natural Language Processing*, pages 375–384. Association for Computational Linguistics.

Xingyi Song, Trevor Cohn, and Lucia Specia. 2013. BLEU deconstructed: Designing a better MT evaluation metric. In *Proceedings of the 14th International Conference on Intelligent Text Processing and Computational Linguistics (CICLING)*, March.

Ilya Sutskever, Oriol Vinyals, and Quoc Le. 2014. Sequence to sequence learning with neural networks. In *Advances in Neural Information Processing Systems (NIPS 2014)*, December.

Matthew D. Zeiler. 2012. ADADELTA: an adaptive learning rate method. Technical report, arXiv 1212.5701.

参考文本

阿米泰·阿克塞尔罗德、何晓东和高建峰。2011年。《通过伪领域内数据选择实现领域适配》。载于自然语言处理经验方法ACL会议（EMNLP）论文集，第355–362页。计算机语言学协会出版。

尼古拉斯·布兰杰-莱万多夫斯基、约书亚·本吉奥与帕斯卡尔·文森特。2013年。《利用循环神经网络实现音频和弦识别》。载于ISMIR会议论文集。

崔京炫、巴特·范·梅里恩布尔、卡格拉尔·古尔-切赫雷、费蒂·布加雷斯、霍尔格·施文克与约书亚·本吉奥。2014年。《利用RNN编解码器为统计机器翻译构建短语表示》。即将收录于《自然语言处理中的经验方法（EMNLP 2014）》会议论文集，出版时间为10月。

亚历克斯·格雷夫斯。2012年。《利用循环神经网络进行序列转换》。载于第29届国际机器学习大会（ICML 2012）会议论文集。

A. 格雷夫斯。2013年。《利用循环神经网络生成序列》。*arXiv:1308.0850 [cs.NE]*., 发布于8月。

S. 霍赫赖特与J. 施密德胡伯。1997年。《长短期记忆》。发表于《神经计算》期刊，第9卷第8期，页码为1735–1780。

纳尔·卡尔奇布伦纳与菲尔·布伦索姆。2013年。《两种循环连续译文模型》。载于自然语言处理经验方法ACL会议（EMNLP）论文集，第1700–1709页。计算语言学协会出版。

菲利普·科恩、弗朗茨·约瑟夫·奥赫以及丹尼尔·马尔库。2003年。《基于短语的统计翻译》。载于2003年计算语言学协会北美分会人类语言技术会议论文集——第1卷，NAACL ’03会议，第48–54页，美国宾夕法尼亚州斯特劳兹堡。计算语言学协会出版。

刘昌、丹尼尔·达尔迈尔与吴慧图。2011年。《更优的评估指标有助于提升机器译文质量》。载于自然语言处理经验方法会议论文集，第375–384页。计算语言学协会出版。

宋行一、Trevor Cohn与Lucia Specia。2013年。《BLEU分数拆解：设计更优的机器翻译评估指标》。载于第14届国际智能文本处理与计算语言学会议（CICLING）论文集，3月出版。

伊利亚·苏茨克维尔、奥里奥尔·维尼亚尔斯与郭科。2014年。《利用神经网络实现序列到序列学习》。载于神经信息处理系统进展（NIPS 2014会议），12月刊。

马修·D·扎伊勒。2012年。《ADADELTA：一种自适应学习率方法》。技术报告，arXiv 1212.5701。